Приложения: таблицы ссылок

*Все **URL** по направлениям собраны ниже.*

Приложение A1. Направление 1 — медицина и сигналы (КТ, рентген, МРТ, ЭКГ, NLP-эпикризы)

Источник	Содержание / особенности	Как стартовать
MosMedData (MosMed.ai)	КТ грудной клетки (в т.ч. COVID-19), публикации и набор `covid19_1110` (описание, Papers with Code); лицензия **CC BY-NC-ND 3.0 — не коммерция**, read-only.	2D/3D срезы, **сегментация** GGO/консолидаций на поднаборе; сравнение U-Net / nnU-Net.
neuro-ml/COVID-19-Triage (GitHub)	Код и пайплайн под **MosMed-1110** и сопутствующие выборки (MedSeg и др.); **мультизадачное** обучение (классификация + сегментация).	Воспроизвести baseline из репозитория; полезен как **скелет** отчёта.
Medical Segmentation Decathlon	10 задач 3D-сегментации (CT/MR): печень, лёгкие, **головной мозг** (опухоль), сердце и др.; эталон для **U-Net-семейства** / MONAI.	Взять **1 задачу** (например, liver / lung) — не грузить все 10. Лицензия **CC BY-SA 4.0**; статья.
RSNA / SIIM COVID-19 Detection (Kaggle)	**Рентген** ОГК (не КТ), локализация/классификация COVID-typical, bounding boxes.	YOLO / классификатор + `Grad-CAM`; удобный **рентген**-бенчмарк при нехватке КТ-диска.
NIH Chest X-rays (Kaggle)	**~112k** снимков ОГК, 14 меток (NLP из отчётов); фронтальный вид.	Многометочная классификация;

		HF-зеркало для `datasets`.
CheXpert (Stanford AIMI)	**~224k** рентгенов, неопределённости в разметке; сильный бенчмарк для chest-CNN.	Регистрация на **AIMI**, **non-commercial**; классика chest-X-ray.
MIMIC-CXR (PhysioNet)	**Сотни тысяч** снимков + текстовые отчёты; VQA / jointly image-text.	Нужен **аккаунт credentialed** PhysioNet (соглашение), не для «быстрый старт в выходные».
LIDC-IDRI (TCIA / Cancer Imaging Archive)	КТ лёгких с **узлами**; аннотации радиологов, контуры.	Детекция/сегментация узла; длинные объёмы — брать **thin slice** подсэмпл.
LUNA16	Подмножество LIDC, фокус на **nodule detection**; соревновательный формат.	Чистая задача **детекции** (FP reduction).
BraTS (MICCAI) (Synapse)	Мультимодальные **МРТ** мозга, опухоль, сегментация регионов.	**Регистрация** на Synapse; 3D-архитектуры, тяжёлый по диску — для сильных групп.
PTB-XL (PhysioNet)	**~21,8k** 12-канальных **ЭКГ** 10 с, 71 клиническая метка (SCP-ECG).	Классификация, 1D-CNN / ResNet; открытая регистрация.
Россия: эпикризы, ИИ-Сеченов	Каталог датасетов ai.sechenov.ru/datasets; в т.ч. **3000+ эпикризов** по лёгочным (анонс новости).	**NLP** по клин. тексту (ICD, извлечение сущностей), а не зрение — как вторая ветка проекта.

Прочие ЭКГ	PhysioNet: *MIT-BIH Arrhythmia*, Chapman-Shaoxing / Ningbo, Georgia 12-lead ECG и др.	Аритмии / классификация; сверяться с лицензией PhysioNet.

*A1. Примечание: проверить **лицензию** (NC/ND), **согласие** (HIPAA, GDPR); для учебы — **одна** модальность на проект.*

Приложение A2. Направление 2 — новости и NLP (русский язык)

Источник	Содержание / особенности	Как стартовать
Lenta.Ru (Kaggle, yutkin)	**800k+** статей (1999–2019), тема/текст/URL; исходник на GitHub.	Классификация **темы**, topic modeling (BERTopic), per-class метрики.
lenta.ru_2 extended (Hugging Face)	Продолжение корпуса Lenta (до **2024**), Parquet, сотни тысяч статей.	Сравнение с «классическим» Lenta; **временной сдвиг** (домен).
Lenta 2020–2023 (Kaggle)	**Свежий** срез Lenta, если нужен период после 2019.	Дозаполнение к yutkin при задаче **актуальных** тем.
RIA: заголовки 2002–2022 (Kaggle)	**Миллионы** заголовков РИА; компактно по диску.	**Классификация/кластер** по «коротким» текстам; **без** полного тела статьи.
Полнотекстовый РИА (~3,7 ГБ, ODS / зеркала)	Крупные дампы **РИА** встречаются в **ODS** и на Kaggle; ссылка на конкретный датасет **различается** — поиск: `ODS РИА новости` /	Проверить **лицензию** копии; дедупликация дат.

	`Kaggle ria fulltext` / `РИА новости dataset`.	
IlyaGusev/ru_news (HF)	**Агрегат** Lenta, **TASS**, Taiga, **Telegram**-контест — единая схема (title, text, time, source).	**Сравнение доменов** (агентства vs Lenta) и **нормализация** даты.
rus_news_classifier (HF)	**~72k** строк, **11** тем (экономика, политика, спорт, …).	Готовая **сбалансированная** метка для **multiclass** (F1-macro).
gazeta.ru-merged (HF)	**Gazeta.ru**: **~138k** материалов, нормальные трейн/тест-сплиты.	+1 источник для **out-of-domain** test относительно Lenta.
Taiga Corpus (HSE)	**~5B** токенов, несколько **подкорпусов** (литература, **новости 4 площадок** и др.), **морфо-/синтаксис** (UD), CC BY-SA.	NER, лемма, **стилистика**; скачивание по частям, не весь 92 ГБ.
Corus (Natasha)	**Единая коллекция** RU: **factRuEval-2016**, **Gareev**, **WiNER** и др. — загрузчики из коробки.	**NER** (PER/LOC/ORG) и парсер новостей; каталог.
RuSentiment + модели	Разметка **тональности** (VK/соцсети) — база для RuBERT-**sentiment** и соседей.	**Анализ тональности**; не путать домен (соцсети) с **Lenta** — явно **domain adaptation**.
Фактчекинг, фейк, stance (RU)	akozlova/RuFacts (бенчмарк согласованности/факта, разбиения train/val/test), strombergnlp/RuStance (stance в	Слой **кризис/модерация**; малые выборки — **кросс-валидация**, не

	комментариях к новостям); плюс поиск на HF: `russian fake news`.	доверять единой случайной split.
Автодетекция «новость vs нет»	Модель desllre/ru_news_detection обучалась на **Taiga**; бинарная **новость/соцсети**.	**Фильтр шума** в пайплайне мониторинга.

*A2. Примечание: **не** нарушать `robots.txt` при самостоятельном скрейпе; **детекция LLM-текстов** — искать обновляемые RU-бенчмарки.*

Приложение A3. Направление 3 — прогноз спроса и ритейл (основные датасеты)

Источник	Содержание / особенности	Как стартовать
M5 Forecasting (Walmart, Kaggle)	Дневные продажи по **иерархии** товар/магазин/штат, цены, календарь, события; крупный эталон для retail-TS.	Сабсет по `state_id` + пару отделов; бейзлайн + LightGBM (часто Tweedie/хвост нулей). Вариант **uncertainty**-трека: M5 — Uncertainty.
Corporación Favorita (Kaggle)	Продуктовый ритейл (Эквадор), промо, праздники, **цена на нефть**, локальные шоки; сильные внешние эффекты.	«Семейства» товаров × магазины; сравнение с/без нефти и промо-флагов. Зеркала: HF store-sales (Favorita) — проверить лицензию.
Rossmann Store Sales (Kaggle)	**Дневные** продажи сети аптек (DE): промо, конкуренты, **holdout**; удобно для split.	XGBoost/LightGBM + календарь; сравнение с сезонной наивной.
H&M Personalized Fashion (Kaggle)	Транзакции fashion-ритейла.	**Спрос** по (артикул, регион) / кластеру; ближе к **ассортименту**.

Olist Brazilian E-Commerce (Kaggle)	**~100k** заказов, статусы, доставка, отзывы, товары.	Заказы/выручка по дням и сегментам.
Instacart Market Basket (Kaggle)	**~3M** заказов, корзины, reorder.	Reorder, next-basket, агрегаты.
UCI Online Retail II	Транзакции (UK), отмены, `CustomerID`.	Ряды; ABC/XYZ.
Russian Retail (Kaggle)	РФ-контекст.	EDA; сверка с Росстат.
Retailrocket e-commerce (Kaggle)	**События**, **~2,7M** транзакций.	Агрегат спроса, воронка.
Monash Time Series — сайт, monash_tsf (HF)	Ряд **Car sales** и др. в `.tsf`.	Бенчмарк TS.
GluonTS — док	`get_dataset("m5")` и др.	**DeepAR**, prob.
Nixtla — datasetsforecast	Поднаборы M5/Favorita.	**StatsForecast** / быстрые эксперименты.
Прочие Kaggle	Поиск: `retail`, `store sales`, `demand`, `Walmart`	Сверить **лицензию**.

A3. Примечание: URL на Kaggle при 404 — искать по точному названию соревнования.

Приложение A3.1. Макро, статистика и внешние ряды (для п.3)

Ресурс	Назначение
FRED (St. Louis Fed)	Макро/розница (США) как ковариаты
Eurostat	Макро ЕС
Росстат / SDDS	Оборот розницы, регионы (**макро-контекст**, не замена микро-SKU)
Brent / WTI	Сырьё; в **Favorita** нефть уже в датасете; иначе — **осторожно** с утечкой
Погодные API	Только с разделением train/test по времени, без **фактической** погоды test в train

---

Приложение A4. Направление 4 — DeepFake / медиа-безопасность